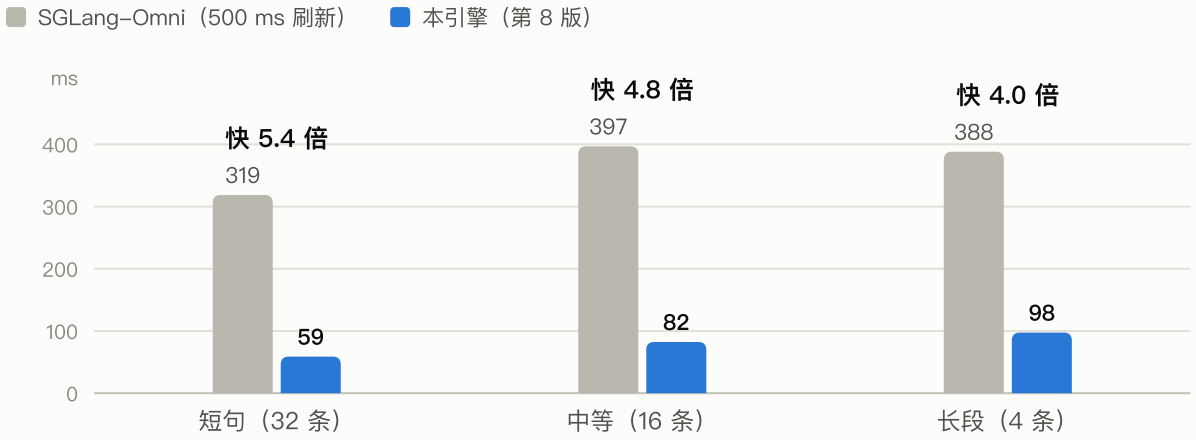
SoL-Pi-Swarm 自动优化 Qwen3-ASR 流式听写，出字延迟加速 4.96 倍

同一模型（Qwen3-ASR 1.7B 6-bit）、同一台 M4 Pro、每 100 ms 实时送入 100 ms 音频。基线为 SGLang-Omni 的 C++/MLX 实时服务，刷新间隔 500 ms，这是 GPU 占用不超过 50% 时它能用的最短间隔。

三组片段的出字延迟降到 59–98 ms

出字延迟：一个字从能被识别出来，到稳定显示在屏幕上的时间，取中位数，越低越好。



加权加速比（短句 0.5、中等 0.35、长段 0.15 的加权几何平均）

4.96 倍

p95 延迟三组都降到 258–348 ms（SGLang-Omni 为 563–702 ms）。回改率短句 0.171、中等 0.113、长段 0.071，均低于 SGLang-Omni。

说完到出最终结果

37–80 ms

SGLang-Omni 为 140–268 ms

离线错误率

4.14%

标准输出 4.42%，392 条全部通过

GPU 占用（说话期间）

43.5%

上限 50%，SGLang-Omni 为 34%

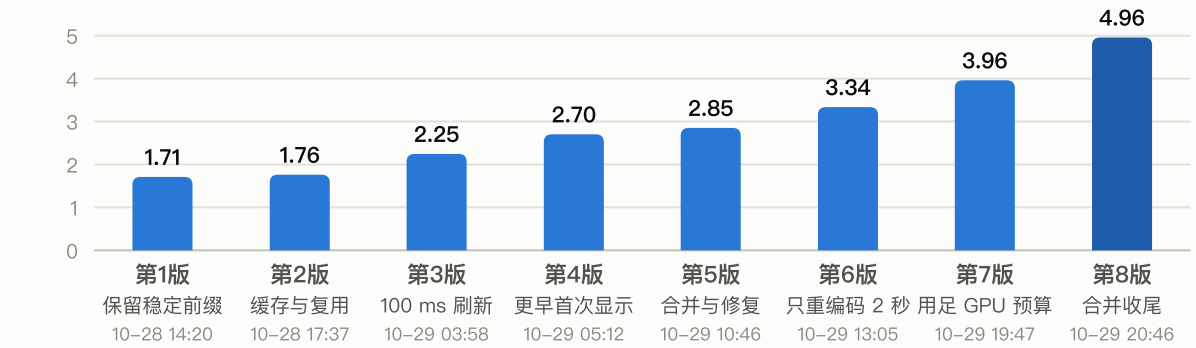
峰值内存

2.6 GB

SGLang-Omni 为 5.1 GB

两天内 8 个有效版本，加速比从 1.71 倍提高到 4.96 倍

纵轴为加权加速比，SGLang-Omni 为 1 倍。每个版本都经过完整评分：392 条离线正确性检查加 52 条实时片段的延迟测量。



优化方法

- **只算新增的音频。** 编码器把已完整的 8 秒窗口结果缓存下来，卷积状态跨刷新保留，预览只重编码最后 2 秒。SGLang-Omni 每次刷新都把当前段从头编码、从头解码。
- **复用已确定的文字。** 已稳定的文字前缀和提示词的 KV 缓存跨刷新复用。新一轮先把上一轮的结果整批核对一遍，只重算有变化的尾部。
- **刷新更频繁。** 每段前 8 秒每 100 ms 刷新一次，之后每 200 ms 一次。SGLang-Omni 为 500 ms，改成 250 ms 时长片段跟不上实时。
- **显示更早也更稳。** 首次显示等待 500 ms，已经稳定的字提前上屏；按识别出的文字切换语言提示，减少中途回改。
- **原生实现，用足 GPU 余量。** C++ 与 Objective-C++ 加自写 Metal kernel，部分从 MLX 0.32.3 移植，预编译并在就绪前预热。预览的 GPU 预算从 45% 提到 52%，总占用仍在 50% 上限以内。

说明

1. 第 7、8 版正式评分时整机有 8%–9% 的背景 GPU 占用，延迟可能略偏乐观；背景干净的第 6 版为 3.34 倍。第 8 版尚未在干净环境下复测。
2. 显示参数是在评分用的 52 条片段上调出来的，在其他语料上的效果没有单独验证。
3. 正确性门槛只检查离线最终文本。实时模式下的最终文本没有设门槛，第 6 版实测错误率 4.02%，标准输出为 3.48%。

评测与过程

延迟：52 条片段按实时节奏送入；正确性：392 条片段离线送入，与标准输出比较错误率。基线：SGLang-Omni qwen3_asr_server @8b81cda（C++/MLX 0.32.3）。优化由 SoL-Pi-Swarm 完成：Opus 5.5 协调，4 个 DeepSeek V4.1 Flash 工作者，10-27 19:53 至 10-29 21:27。